

RAG系统概述

检索增强生成（Retrieval-Augmented Generation，简称RAG）是一种将信息检索与大型语言模型相结合的技术。当用户提出问题时，系统首先从知识库中检索相关文档，然后将这些文档输入到大语言模型中，生成准确且有依据的回答。这种方法能够显著减少模型的幻觉现象，并在不需要重新训练模型的情况下保持答案的时效性。

RAG系统通常包含三个主要组件：文档摄入管道，负责解析和切分文档；向量数据库，用于存储嵌入向量；以及检索与生成循环，负责找到相关的文档块并合成答案。此外，系统还需要支持多种文档格式，包括PDF、Word、Excel等常见办公文件格式。